



Hacettepe Üniversitesi İstatistik Bölümü

İST489 – Zaman Serileri Analizi

Dönem Ödevi

22.12.2025

Prof. Dr. Cem KADILAR

Arş. Gör. Dr. Ceren ÜNAL AKDENİZ

Zehra Oynaş - 2220329027

İçindekiler

1. Veri Seti.....	3
2. Zaman Serileri Analizi.....	4
3. Ayırıştırma Yöntemleri.....	6
3.1 Toplamsal Ayırıştırma Modeli.....	7
3.2 Çarpımsal Ayırıştırma Modeli.....	8
4. Regresyon Analizi.....	9
4.1 Toplamsal Regresyon Modeli.....	9
4.2 Çarpımsal Regresyon Modeli.....	13
5. Üstel Düzleştirme Yöntemi.....	17
5.1 Toplamsal Winters Üstel Düzleştirme Yöntemi.....	17
5.2 Çarpımsal Winters Üstel Düzleştirme Yöntemi.....	20
.....	21
6. Box Jenkins Modelleri.....	22
6.1 ARIMA Modelleri.....	23
6.2 Öngörü.....	43
7. Kodlar.....	44
8. Kaynakça.....	72

1. Veri Seti

Zaman serisi analizi uygulaması için TCMB EVDS veri tabanından alınan Sanayi Üretim Endeksi verileri kullanılmıştır. Sektör olarak Tekstil Ürünlerinin İmalatı (TP.SAN.Y01) seçilmiştir. Veri seti Haziran 2005 başlangıç ve Aralık 2017 bitiş tarihli olup 151 adet gözlem içermektedir.

Tanımlayıcı İstatistikler:

```
> summary(data)
```

TP N2SY16

Min. : 73.59

1st Qu.:101.84

Median :108.71

Mean :107.65


3rd Qu.:115.54

Max. :126.78

Serinin ortalama değerinin 107.65, medyan değerinin ise 108.71 olduğu görülmektedir. Ortalama ve medyan değerlerinin birbirine yakın olması, verinin dağılımının simetriğe yakın olduğunu göstermektedir. İncelenen dönem boyunca (2005-2017) sanayi üretim endeksinin en düşük 73.59, en yüksek ise 126.78 seviyelerinde olduğu görülmektedir. Verilerin %50'sini kapsayan çeyrekler arası aralık (1. Çeyrek - 3. Çeyrek) ise 101.84 ile 115.54 arasında yoğunlaşmıştır.


2. Zaman Serileri Analizi

EVDS Verisi Zaman Serisi




Zaman serisi grafiğine bakıldığında dalgalanmaların olduğu söylenebilir. Mevsimsellik ve trendten şüphelenilir. Daha kesin bir yorum için ACF ve PACF grafiklerine bakılır.

ACF Grafiği




PACF Grafiği




Otokorelasyon fonksiyonu yani ACF grafiğine bakıldığında baskın bir şekilde trend olduğu görülüyor. Dalgalanmalardan dolayı mevsimsellikten şüphe edilir. 1. Dereceden trend için fark alınır.

Öncelikle trend için 1. Dereceden fark alınır:


1. Dereceden Farkı Alınmış Seri



1. Trend Farkı Alınmış Serinin ACF Grafiği




1. Tren Farkı Alınmış Serinin PACF Grafiği




Serinin trendten arındırıldığı görülmektedir.


Mevsimsellikten arındırmak için şimdi de mevsimsel için 1.fark alınır.

Trend + 1. Mevsimsel Farkı Alınmış Seri





Mevsimsellik için 2. fark da alınır.




Serinin son durumda hem trentten hem mevsimsellikten arındırıldığı görülmektedir.

3. Ayırıştırma Yöntemleri

Zaman serisini bileşenlerine ayırarak her bir bileşen için tahminleri içeren ve bu bileşenlerin tahmininden zaman serisinin öngörüsünü hesaplayan yönteme “Ayırıştırma Yöntemleri” denir.


3.1 Toplamsal Ayırıştırma Modeli

Orijinal seri ile tahmin serisinin uyumu:



Grafiğe bakıldığında orijinal seri ile tahmin serisinin uyuşmadığı görülmektedir. Seri için bu modelin uygun olmadığı düşünülmektedir ancak diğer testlere de bakılması gerekir.

Hataların akgürültülü olması varsayımı:



Acf grafiğinde gecikmelerin sınır dışında olması akgürültü olmadığını gösterir. Box-Ljung testi yapılır.

Ho: Hatalar arasında ilişki yoktur.

Hs: Hatalar arasında ilişki vardır.

Box-Ljung test

data: hata


X-squared = 516.48, df = 24, p-value < 2.2e-16

p-value < 0.05 olduğu için yokluk hipotezi reddedilir. %95 Güven düzeyinde hataların akgürültü serisi olmadığını yani hatalar arasında ilişki olduğunu söylenebilir. Sonuç olarak toplamsal ayrıştırma modelinin anlamlı olmadığı sonucuna varılır.

[1] "Toplamsal HKO: 9.61161624547283"


3.2 Çarpımsal Ayrıştırma Modeli

Orijinal seri ile tahmin serisinin uyumu:



Grafiğe bakıldığında orijinal seri ile tahmin serisinin uyuşmadığı görülmektedir. Seri için bu modelin uygun olmadığı düşünülmektedir ancak diğer testlere de bakılması gerekir.

Hataların akgürültülü olması varsayımı:



Acf grafiğinde gecikmelerin sınır dışında olması akgürültü olmadığını gösterir. Box-Ljung testi yapılır.

Ho: Hatalar arasında ilişki yoktur.

Hs: Hatalar arasında ilişki vardır.

Box-Ljung test

data: hata1

X-squared = 516.84, df = 24, p-value < 2.2e-16

p-value < 0.05 olduğu için yokluk hipotezi reddedilir. %95 Güven düzeyinde hataların akgürültü serisi olmadığını yani hatalar arasında ilişki olduğunu söylenebilir. Sonuç olarak çarpımsal ayrıştırma modelinin anlamlı olmadığı sonucuna varılır.

[1] "Çarpımsal HKO: 9.60943608848313"

Eğer her iki ayrıştırma modeli de anlamlı çıksaydı hata kareler ortalaması (HKO) küçük olanı seçerdik. Burada her iki model de anlamsız çıktığı için seride ayrıştırma modelleri kullanılmayacaktır.

4. Regresyon Analizi

4.1 Toplamsal Regresyon Modeli

Periyot 12 olduğundan formüle göre en fazla 6.harmoniğe kadar gidilebilir ancak pratikte en fazla 4.harmoniğe gidilebildiği göz ardı edilmemelidir.

Birinci (j=1) harmonik durumunda model ve anlamlılığı:

Doğrusal regresyon modeli oluşturuldu.

Call:

```
lm(formula = y ~ t + sin1 + cos1, data = veriseti_reg)
```

Residuals:

Min	1Q	Median	3Q	Max
-478.84	-92.85	12.13	122.28	297.18

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1053.4467	26.1631	40.265	<2e-16 ***
t	-0.1122	0.2986	-0.376	0.708
sin1	0.1704	18.4434	0.009	0.993
cos1	-1.5157	18.3782	-0.082	0.934

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 159.9 on 147 degrees of freedom

Multiple R-squared: 0.001001, Adjusted R-squared: -0.01939

F-statistic: 0.04912 on 3 and 147 DF, p-value: 0.9855

Ho: Regresyon modeli anlamsızdır.

Hs: Regresyon modeli anlamlıdır.

P – value değeri = 0.985 > 0.05 olduğundan Ho reddedilemez. %95 Güven düzeyinde modelin anlamsız olduğu söylenebilir.

Ho: Modelin katsayıları anlamsızdır.

Hs: Modelin katsayıları anlamlıdır.

%95 Güven düzeyinde tüm katsayıların anlamsız olduğu söylenebilir.

Analiz sürecinde, başlangıçta kurulan Model 1'in ve katsayılarının istatistiksel olarak anlamsız olduğu görülmüştür. Ancak, zaman serisinin grafiksel yapısındaki sık dalgalanmalar dikkate alınarak, seride daha kısa vadeli (6 aylık) döngülerin etkili olabileceği düşünülmüş ve ikinci harmoniğe geçilerek Model 2 denenmiştir.

Call:

```
lm(formula = y ~ t + sin1 + cos1 + sin2 + cos2, data = veriseti_reg)
```

Residuals:

Min	1Q	Median	3Q	Max
-440.93	-91.82	31.18	100.41	288.97

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1056.1308	24.5974	42.937	< 2e-16 ***
t	-0.1479	0.2807	-0.527	0.5991
sin1	1.4576	17.3388	0.084	0.9331
cos1	0.5827	17.2802	0.034	0.9731
sin2	-37.0861	17.2751	-2.147	0.0335 *
cos2	71.2982	17.3381	4.112	6.54e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 150.3 on 145 degrees of freedom

Multiple R-squared: 0.1295, Adjusted R-squared: 0.09951

F-statistic: 4.315 on 5 and 145 DF, p-value: 0.001089

Ho: Regresyon modeli anlamsızdır.

Hs: Regresyon modeli anlamlıdır.


P – value değeri = 0.00 < 0.05 olduğundan Ho reddedilir. %95 Güven düzeyinde modelin anlamlı olduğu söylenebilir.

Ho: Modelin katsayıları anlamsızdır.

Hs: Modelin katsayıları anlamlıdır.

%95 Güven düzeyinde sin2 ve cos2 katsayılarının anlamlı olduğu söylenebilir.

Yapılan deneme sonucunda 2. Harmoniklerin (sin2, cos2) modele anlamlı bir katkı sağladığı görülmektedir.



Orijinal seri ile tahminin alt ve üst sınırlarının birlikte grafiğine bakıldığında birçok verinin tahmin sınırları dışında kaldığı söylenebilir. Seri için bu modelin çok uygun olmadığı düşünülür ancak diğer testlere de bakılması gerekir.

Durbin – Watson Testi:

$$H_0 : \rho = 0$$

$$H_s : \rho \neq 0$$


Durbin-Watson test

data: secilen_model

DW = 0.83515, p-value = 5.354e-14

alternative hypothesis: true autocorrelation is greater than 0

Durbin Watson testine göre elde edilen p değeri 0.05'ten küçük olduğu için hatalar arasında özilişki olduğu %95 güven düzeyinde söylenebilir ancak Box-Ljung testine de bakılması gerekir.



Box – Ljung Testi:

Ho: Hatalar arasında ilişki yoktur.

Hs: Hatalar arasında ilişki vardır.

Box-Ljung test

data: hata_reg

X-squared = 472.47, df = 24, p-value < 2.2e-16

Box – Ljung testinden elde edilen p değeri 0.05'ten küçük olduğu için Ho reddedilir. Hatalar arasında ilişki olduğu %95 güven düzeyinde söylenebilir. Böylece hata serisinin akgürültü serisi olmadığını, serinin toplamsal model ile modellenemeyeceğini ve ön görüşünün yapılamayacağı söylenebilir.

4.2 Çarpımsal Regresyon Modeli

Periyot 12 olduğundan formüle göre en fazla 6.harmoniğe kadar gidilebilir ancak pratikte en fazla 4.harmoniğe gidilebildiği göz ardı edilmemelidir.

Birinci (j=1) harmonik durumunda model ve anlamlılığı:

Doğrusal regresyon modeli oluşturuldu.

Call:

```
lm(formula = y ~ t + sin1_c + cos1_c, data = veriseti_carpim1)
```

```

Residuals:
    Min     1Q   Median     3Q      Max
-490.66 -95.62  14.38 118.79 299.05

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 1053.03517   26.01581  40.477  <2e-16 ***
            t         -0.10373    0.29723  -0.349   0.728
            sin1_c     -0.25956    0.21112  -1.229   0.221
            cos1_c     -0.09794    0.20700  -0.473   0.637
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```

Residual standard error: 159 on 147 degrees of freedom
Multiple R-squared:  0.01263,    Adjusted R-squared: -0.007523
F-statistic: 0.6267 on 3 and 147 DF, p-value: 0.5989

```

Ho: Regresyon modeli anlamsızdır.

Hs: Regresyon modeli anlamlıdır.

P değeri 0.05'ten büyük olduğu için Ho hipotezi reddedilemez. Modelin anlamsız olduğu %95 güven düzeyinde söylenebilir.

Ho: Modelin katsayıları anlamsızdır.

Hs: Modelin katsayıları anlamlıdır.

Yorum yap Hem F-testi sonucunda modelin genelinin anlamsız çıkması, hem de t-testleri sonucunda katsayıların anlamsız bulunması nedeniyle Model 1 başarısızdır.

İkinci harmoniğe (j=2) geçilerek Model 2 denenmiştir.

```

Call:
lm(formula = y ~ t + sin1_c + cos1_c + sin2_c + cos2_c, data = veriseti_carpim2)

```

```

Residuals:
    Min     1Q   Median     3Q      Max

```

-454.19 -93.69 14.32 102.99 296.42

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1054.60847	24.60174	42.867	< 2e-16 ***
t	-0.13457	0.28115	-0.479	0.632915
sin1_c	-0.23600	0.19980	-1.181	0.239456
cos1_c	-0.06389	0.19587	-0.326	0.744739
sin2_c	-0.37533	0.19752	-1.900	0.059384 .
cos2_c	0.79107	0.19784	3.999	0.000101 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 150.3 on 145 degrees of freedom

Multiple R-squared: 0.1293, Adjusted R-squared: 0.09927

F-statistic: 4.306 on 5 and 145 DF, p-value: 0.001107

Ho: Regresyon modeli anlamsızdır.


Hs: Regresyon modeli anlamlıdır.

P değeri 0.05'ten küçük olduğu için Ho hipotezi reddedilir. Modelin anlamlı olduğu %95 güven düzeyinde söylenebilir.

Ho: Modelin katsayıları anlamsızdır.

Hs: Modelin katsayıları anlamlıdır.

Çarpımsal Regresyon (Model 2)



Orijinal seri ile tahminin alt ve üst sınırlarının birlikte grafiğine bakıldığında birçok verinin tahmin sınırları dışında kaldığı söylenebilir. Tahmin sınırlarının özellikle ani dalgalanmaları yakalayamadığı görülmektedir. Seri için bu modelin çok uygun olmadığı düşünülür ancak diğer testlere de bakılması gerekir.

Durbin – Watson Testi:

$$H_0 : \rho = 0$$

$$H_s : \rho \neq 0$$


Durbin-Watson test

data: secilen_model_carpim

DW = 0.85365, p-value = 1.244e-13

alternative hypothesis: true autocorrelation is greater than 0

Durbin Watson testine göre elde edilen p değeri 0.05'ten küçük olduğu için hatalar arasında özilişki olduğu %95 güven düzeyinde söylenebilir ancak Box-Ljung testine de bakılması gerekir.



Box – Ljung Testi:

Ho: Hatalar arasında ilişki yoktur.

Hs: Hatalar arasında ilişki vardır.

Box-Ljung test

data: hata_carpim

X-squared = 463.29, df = 24, p-value < 2.2e-16

Box – Ljung testinden elde edilen p değeri 0.05'ten küçük olduğu için Ho reddedilir. Hatalar arasında ilişki olduğu %95 güven düzeyinde söylenebilir. Böylece hata serisinin akgürültü serisi olmadığını, serinin çarpımsal model ile modellenemeyeceğini ve ön görüşünün yapılamayacağı söylenebilir.

5. Üstel Düzleştirme Yöntemi

Trende ve mevsimselliğe sahip serilerin tahmininde üstel düzleştirme yöntemlerinden Winters üstel düzleştirme yöntemi kullanılmaktadır.

5.1 Toplamsal Winters Üstel Düzleştirme Yöntemi

ETS(A,A,A)

Call:

```
ets(y = veri_ts, model = "AAA")
```

Smoothing parameters:

alpha = 0.3731

beta = 1e-04

gamma = 1e-04

Initial states:

l = 116.001

b = -0.0082

s = 4.0943 1.9083 5.6046 -6.5749 -5.6524 1.6949

3.8588 4.4882 -1.3624 -5.3095 -4.4137 1.6639

sigma: 6.8446

AIC AICc BIC

1355.580 1360.181 1406.874

Training set error measures:

ME RMSE MAE MPE MAPE MASE


Training set 0.01817507 6.471786 4.863721 -0.3132155 4.690908 0.6294526

ACF1

Training set -0.1592171


Modelin çıktıları incelendiğinde; ortalama düzeyin (l) başlangıç değeri 116.001, eğimin (b) başlangıç değeri -0.0082 ve mevsimsel bileşenlerin başlangıç değerleri (s) 4.0943 elde edilmiştir. Bu başlangıç değerleri esas alınarak hesaplanan optimal düzleştirme katsayıları; düzey parametresi (α) için 0.3731, trend (β) ve mevsimsellik (γ) parametreleri için ise yaklaşık 0 (0.0001) olarak bulunmuştur. Trend ve mevsimsellik parametrelerinin sıfıra çok yakın olması, serideki bu yapıların zaman içerisinde belirgin bir değişim göstermediğini ve modelin ağırlıklı olarak düzey değişimlerini dikkate aldığını işaret etmektedir. Modelin performans göstergeleri değerlendirildiğinde; AIC değerinin 1355.580 , Hata Kareler Ortalaması (RMSE) değerinin ise 6.4718 olduğu görülmektedir.

Toplamsal Winters Metodu (AAA)




Modelden elde edilen tahmin değerlerinin (kırmızı kesikli çizgi), gerçek zaman serisi verileri (siyah çizgi) ile yüksek bir şekilde uyumlu olduğu görülmektedir. Özellikle önceki modellerden farklı olarak ani iniş çıkışlarla da uyumlu olduğu söylenebilir.

Toplamsal Winters Hataları (ACF)



Toplamsal Winters Hataları (PACF)



Gecikmelerden bazılarının sınır dışında olması akgürültü olmadığını gösterir. Box-Ljung testi yapılır.

Box – Ljung Testi:

Ho: Hatalar arasında ilişki yoktur.

Hs: Hatalar arasında ilişki vardır.

Box-Ljung test

data: hata_winters_top

X-squared = 90.539, df = 24, p-value = 1.174e-09

Elde edilen p değerine göre Ho reddedilir. Hatalar arasında ilişki vardır. Hata serisi akgürültü değildir. Toplamsal Winters yöntemi seri için uygun değildir.

5.2 Çarpımsal Winters Üstel Düzleştirme Yöntemi

ETS(M,Ad,M)

Call:

```
ets(y = abs(veri_ts), model = "MAM")
```

Smoothing parameters:

alpha = 0.3858

beta = 1e-04

gamma = 1e-04

phi = 0.9799

Initial states:

l = 116.1781

b = 0.1096

s = 1.0369 1.0183 1.0472 0.9368 0.9467 1.0195

1.0392 1.0437 0.988 0.9495 0.962 1.0123

sigma: 0.0653

AIC AICc BIC

1363.692 1368.874 1418.003

Training set error measures:

ME RMSE MAE MPE MAPE MASE

Training set -0.1048108 6.517828 4.88858 -0.4228509 4.715966 0.6326698


ACF1

Training set -0.1636335



Modelin çıktıları incelendiğinde; ortalama düzeyin (l) başlangıç değeri 116.1781, eğimin (b) başlangıç değeri 0.1096 ve mevsimsel bileşenlerin başlangıç değerleri (s) 1.0369 elde edilmiştir. Bu başlangıç değerleri esas alınarak hesaplanan optimal düzleştirme katsayıları; düzey parametresi (α) için 0.3858, trend (β) ve mevsimsellik (γ) parametreleri için ise yaklaşık 0 (0.0001) olarak bulunmuştur. Phi parametresi 0.9799 olarak elde edilmiştir, modelin trendinin 'Sönümlü' (Damped) olduğunu göstermektedir. Bu durum, modelin

geleceğe yönelik tahmin yaparken trendi sonsuza kadar doğrusal uzatmak yerine, zamanla sönümleyerek daha gerçekçi tahminler ürettiğini ifade eder.

Trend ve mevsimsellik parametrelerinin sıfıra çok yakın olması, serideki bu yapıların zaman içerisinde belirgin bir değişim göstermediğini ve modelin ağırlıklı olarak düzey değişimlerini dikkate aldığını işaret etmektedir. Modelin performans göstergeleri değerlendirildiğinde; AIC değerinin 1363.692 , Hata Kareler Ortalaması (RMSE) değerinin ise 6.5178 olduğu görülmektedir.



Modelden elde edilen tahmin değerlerinin (kırmızı kesikli çizgi), gerçek zaman serisi verileri (siyah çizgi) ile yüksek bir şekilde uyumlu olduğu görülmektedir.



Box – Ljung Testi:

Ho: Hatalar arasında ilişki yoktur.

Hs: Hatalar arasında ilişki vardır.

Box-Ljung test


data: hata_winters_c

X-squared = 85.939, df = 24, p-value = 6.703e-09


Elde edilen p değerine göre Ho reddedilir. Hatalar arasında ilişki vardır. Hata serisi akgürültü değildir. Çarpımsal Winters yöntemi seri için uygun değildir.

6. Box Jenkins Modelleri

Orijinal zaman serisinin ACF ve PACF grafikleri şu şekilde:



Zaman serileri analizi adımımda seriyi durağanlaştırmak için önce 1.dereceden trent farkı alınmıştır, ardından mevsimsellik için 2 kez fark alınıp seri durağanlaştırılmıştır.



Durağanlaşan serinin ACF ve PACF grafiklerine bakıldığında ACF grafiğinin PACF grafiğine göre daha yavaş azaldığı görülmektedir. Buna göre seriye uygun model otoregresyon modelidir. Ancak denemeden kesin bir yargıya varılamaz. PACF grafiğinde sadece ilk gecikmeye ait ilişki önemli olduğundan $p=1$ 'dir. İki kez mevsimsel fark alındığından $D=2$, bir kez trent için fark alındığından $d=1$ 'dir. Periyodun etrafındaki gecikmelerde önemli bir ilişki olduğundan $P=1$ olarak düşünülür ancak denemeden kesin bir yargıya varılamaz.

6.1 ARIMA Modelleri

İlk aşamada seriye uygun model $ARIMA(1,1,0)(1,2,0)_{12}$ olmaktadır.

$ARIMA(1, 1, 0)(1, 2, 0)_{12}$

H_0 : $ARIMA(1,1,0)(1,2,0)_{12}$ modeli anlamsızdır.

H_s : $ARIMA(1,1,0)(1,2,0)_{12}$ modeli anlamlıdır.

z test of coefficients:

```

      Estimate Std. Error z value Pr(>|z|)
ar1 -0.618107  0.071429 -8.6535 < 2.2e-16 ***
sar1 -0.490080  0.082529 -5.9383 2.881e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```
> summary(arima2)
```

```
Series: veri_ts
```

ARIMA(1,1,0)(1,2,0)[12]

Coefficients:

ar1 sar1

-0.6181 -0.4901

s.e. 0.0714 0.0825

sigma^2 = 90.68: log likelihood = -467.46

AIC=940.92 AICc=941.12 BIC=949.43

Training set error measures:

ME RMSE MAE MPE MAPE MASE

Training set 0.2524157 8.629151 5.95166 0.2164591 5.721824 0.7702513

ACF1

Training set -0.006559926

Elde edilen çıktıya göre ar1 ve sar1 katsayılarının önemli ($p < 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(1,1,0)(1,2,0)_{12}$ modelinin anlamlı olduğu söylenebilir.

RMSE = 8.629151 ve BIC = 949.43 olarak elde edilmiştir. Birden fazla anlamlı model olması durumunda bu bilgi kriterleri ile model seçilecektir.

Uygun olan farklı kombinasyon denemeleri:

ARIMA(1, 1, 0)(2, 2, 0)₁₂

Ho: $ARIMA(1,1,0)(2,2,0)_{12}$ modeli anlamsızdır.

Hs: $ARIMA(1,1,0)(2,2,0)_{12}$ modeli anlamlıdır.

z test of coefficients:

Estimate Std. Error z value Pr(>|z|)

ar1 -0.706741 0.066386 -10.6460 < 2.2e-16 ***

sar1 -0.728174 0.092624 -7.8616 3.793e-15 ***

sar2 -0.420105 0.093179 -4.5086 6.526e-06 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> summary(arima3)

Series: veri_ts

ARIMA(1,1,0)(2,2,0)[12]

Coefficients:

ar1 sar1 sar2

-0.7067 -0.7282 -0.4201

s.e. 0.0664 0.0926 0.0932

sigma^2 = 76.86: log likelihood = -459.12

AIC=926.24 AICc=926.57 BIC=937.58

Training set error measures:

ME RMSE MAE MPE MAPE MASE

Training set 0.3473381 7.912294 5.332157 0.2607843 5.149443 0.6900765

ACF1

Training set -0.08910619

Elde edilen çıktıya göre ar1, sar1 ve sar2 katsayılarının önemli ($p < 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(1,1,0)(2,2,0)_{12}$ modelinin anlamlı olduğu söylenebilir.

RMSE = 7.912294 ve BIC = 937.58 olarak elde edilmiştir. Birden fazla anlamlı model olması durumunda bu bilgi kriterleri ile model seçilecektir.

ARIMA(1, 1, 0)(3, 2, 0)₁₂

Ho: $ARIMA(1,1,0)(3,2,0)_{12}$ modeli anlamsızdır.

Hs: $ARIMA(1,1,0)(3,2,0)_{12}$ modeli anlamlıdır.

z test of coefficients:

Estimate Std. Error z value Pr(>|z|)

ar1 -0.685017 0.072575 -9.4388 < 2.2e-16 ***

sar1 -0.845738 0.100980 -8.3753 < 2.2e-16 ***

sar2 -0.633313 0.114675 -5.5227 3.339e-08 ***

sar3 -0.341045 0.108747 -3.1361 0.001712 **

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> summary(arima4)
```

```
Series: veri_ts
```

```
ARIMA(1,1,0)(3,2,0)[12]
```

```
Coefficients:
```

```
ar1 sar1 sar2 sar3
```

```
-0.6850 -0.8457 -0.6333 -0.3410
```

```
s.e. 0.0726 0.1010 0.1147 0.1087
```

```
sigma^2 = 70.28: log likelihood = -454.81
```

```
AIC=919.62 AICc=920.12 BIC=933.8
```

```
Training set error measures:
```

```
ME RMSE MAE MPE MAPE MASE
```

```
Training set 0.349001 7.53568 5.013182 0.2523412 4.85096 0.6487955
```

```
ACF1
```

```
Training set -0.08863609
```

Elde edilen çıktıya göre ar1, sar1, sar2 ve sar3 katsayılarının önemli ($p < 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(1,1,0)(3,2,0)_{12}$ modelinin anlamlı olduğu söylenebilir.

RMSE = 7.53568 ve BIC = 933.8 olarak elde edilmiştir. Birden fazla anlamlı model olması durumunda bu bilgi kriterleri ile model seçilecektir.

$ARIMA(1, 1, 0)(0, 2, 0)_{12}$

Ho: $ARIMA(1,1,0)(0,2,0)_{12}$ modeli anlamsızdır.

Hs: $ARIMA(1,1,0)(0,2,0)_{12}$ modeli anlamlıdır.

```
z test of coefficients:
```

```
Estimate Std. Error z value Pr(>|z|)
```

```
ar1 -0.49076 0.07719 -6.3578 2.047e-10 ***
```

```
---
```

```
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
> summary(arima1)
```

```
Series: veri_ts
```

```
ARIMA(1,1,0)(0,2,0)[12]
```

```
Coefficients:
```

```
ar1
```

```
-0.4908
```

```
s.e. 0.0772
```

```
sigma^2 = 115.6: log likelihood = -481.5
```

```
AIC=967.01 AICc=967.11 BIC=972.68
```

```
Training set error measures:
```

```
ME RMSE MAE MPE MAPE MASE
```

```
Training set 0.2147873 9.780425 6.720089 0.2230527 6.489747 0.8696998
```

```
ACF1
```

```
Training set -0.01127909
```

Elde edilen çıktıya göre ar1 katsayısının önemli ($p < 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(1,1,0)(0,2,0)_{12}$ modelinin anlamlı olduğu söylenebilir.

RMSE = 9.780425 ve BIC = 972.68 olarak elde edilmiştir. Birden fazla anlamlı model olması durumunda bu bilgi kriterleri ile model seçilecektir.

$ARIMA(1,1,0)(1,2,1)_{12}$

Ho: $ARIMA(1,1,0)(1,2,1)_{12}$ modeli anlamsızdır.

Hs: $ARIMA(1,1,0)(1,2,1)_{12}$ modeli anlamlıdır.

```
z test of coefficients:
```

```
Estimate Std. Error z value Pr(>|z|)
```

```
ar1 -0.655672 0.069365 -9.4525 <2e-16 ***
```

```
sar1 -0.124021 0.100572 -1.2331 0.2175
```

```
sma1 -0.995238 0.097377 -10.2205 <2e-16 ***
```

```
---
```

```
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
> summary(arima7)
```

Series: veri_ts

ARIMA(1,1,0)(1,2,1)[12]

Coefficients:

ar1 sar1 sma1

-0.6557 -0.1240 -0.9952

s.e. 0.0694 0.1006 0.0974

sigma^2 = 53.93: log likelihood = -448.22

AIC=904.45 AICc=904.78 BIC=915.79

Training set error measures:

ME RMSE MAE MPE MAPE MASE

Training set 0.4235383 6.628102 4.398922 0.311371 4.256867 0.5692992

ACF1

Training set -0.0761994

Elde edilen çıktıya göre ar1 ve sma1 katsayılarının önemli ($p < 0.05$) ancak sar1 katsayısının önemsiz olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(1,1,0)(1,2,1)_{12}$ modelinin anlamsız olduğu söylenebilir.

$ARIMA(1, 1, 0)(0, 2, 1)_{12}$

Ho: $ARIMA(1,1,0)(0,2,1)_{12}$ modeli anlamsızdır.

Hs: $ARIMA(1,1,0)(0,2,1)_{12}$ modeli anlamlıdır.

z test of coefficients:

Estimate Std. Error z value Pr(>|z|)

ar1 -0.630664 0.068464 -9.2116 < 2.2e-16 ***

sma1 -0.996034 0.088927 -11.2006 < 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> summary(arima5)
```

Series: veri_ts

ARIMA(1,1,0)(0,2,1)[12]

Coefficients:

ar1 sma1

-0.6307 -0.9960

s.e. 0.0685 0.0889

sigma^2 = 55.29: log likelihood = -448.95

AIC=903.9 AICc=904.1 BIC=912.41

Training set error measures:

ME RMSE MAE MPE MAPE MASE

Training set 0.4046831 6.737989 4.469406 0.3054315 4.326306 0.5784212

ACF1

Training set -0.05829515

Elde edilen çıktıya göre ar1 ve sma1 katsayılarının önemli ($p < 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(1,1,0)(0,2,1)_{12}$ modelinin anlamlı olduğu söylenebilir.

RMSE = 6.737989 ve BIC = 912.41 olarak elde edilmiştir. Birden fazla anlamlı model olması durumunda bu bilgi kriterleri ile model seçilecektir.

ARIMA(1, 1, 0)(0, 2, 2)₁₂

Ho: $ARIMA(1,1,0)(0,2,2)_{12}$ modeli anlamsızdır.

Hs: $ARIMA(1,1,0)(0,2,2)_{12}$ modeli anlamlıdır.

z test of coefficients:

Estimate Std. Error z value Pr(>|z|)

ar1 -0.664412 0.068628 -9.6813 < 2.2e-16 ***

sma1 -1.182643 0.168246 -7.0293 2.076e-12 ***

sma2 0.187373 0.131642 1.4234 0.1546

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

> summary(arima6)

Series: veri_ts

ARIMA(1,1,0)(0,2,2)[12]

Coefficients:

ar1 sma1 sma2

-0.6644 -1.1826 0.1874

s.e. 0.0686 0.1682 0.1316

sigma^2 = 52.78: log likelihood = -447.89

AIC=903.78 AICc=904.11 BIC=915.13

Training set error measures:

ME RMSE MAE MPE MAPE MASE

Training set 0.4280621 6.556864 4.384089 0.3095097 4.243126 0.5673796

ACF1

Training set -0.08862178

Elde edilen çıktıya göre ar1 ve sma1 katsayılarının önemli ($p < 0.05$) ancak sma2 katsayısının önemsiz olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(1,1,0)(0,2,2)_{12}$ modelinin anlamsız olduğu söylenebilir.

ARIMA(1, 1, 0)(2, 2, 1)₁₂ : sar1 ve sar2 katsayıları önemsiz olduğundan model anlamsızdır.

Grafikteki azalmaların yanlış yorumlanması ihtimaline karşı diğer durumlar da gözden geçirilecektir.

PACF grafiğinin ACF grafiğine göre daha yavaş azalması durumunda seriye uygun olan model hareketli ortalama modelidir (MA). ACF grafiğinde ilk iki gecikmeye ait ilişki önemli olduğundan $q=2$ 'dir. İki kez mevsimsel fark alındığından $D=2$, bir kez trend için fark alındığından $d=1$ 'dir. Periyodun etrafındaki gecikmeler aynı yönlü olduğundan $Q=1$ olarak düşünülür ancak denemeden kesin bir yargıya varılamaz.

İlk aşamada seriye uygun model $ARIMA(0,1,2)(0,2,1)_{12}$ olmaktadır.

ARIMA(0, 1, 2)(0, 2, 1)₁₂

Ho: $ARIMA(0,1,2)(0,2,1)_{12}$ modeli anlamsızdır.

Hs: $ARIMA(0,1,2)(0,2,1)_{12}$ modeli anlamlıdır.

z test of coefficients:

```

Estimate Std. Error z value Pr(>|z|)
ma1 -0.592195 0.076590 -7.7320 1.059e-14 ***
ma2 0.382551 0.102325 3.7386 0.0001851 ***
sma1 -0.996092 0.088332 -11.2766 < 2.2e-16 ***
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```
> summary(arima10)
```

```
Series: veri_ts
```

```
ARIMA(0,1,2)(0,2,1)[12]
```

```
Coefficients:
```

```

ma1  ma2  sma1
-0.5922 0.3826 -0.9961
s.e. 0.0766 0.1023 0.0883

```

```
sigma^2 = 56.42: log likelihood = -449.73
```

```
AIC=907.47 AICc=907.8 BIC=918.81
```

```
Training set error measures:
```

```
ME RMSE MAE MPE MAPE MASE
```

```
Training set 0.3384347 6.778962 4.464266 0.2547234 4.304202 0.5777559
```

```
ACF1
```

```
Training set -0.07662858
```

Elde edilen çıktıya göre $ma1$, $ma2$ ve $sma1$ katsayılarının önemli ($p < 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(0,1,2)(0,2,1)_{12}$ modelinin anlamlı olduğu söylenebilir.

RMSE = 6.778962 ve BIC = 918.81 olarak elde edilmiştir. Birden fazla anlamlı model olması durumunda bu bilgi kriterleri ile model seçilecektir.

$ARIMA(0, 1, 2)(0, 2, 2)_{12}$

H_0 : $ARIMA(0,1,2)(0,2,2)_{12}$ modeli anlamsızdır.

H_s : $ARIMA(0,1,2)(0,2,2)_{12}$ modeli anlamlıdır.

```
z test of coefficients:
```

```
Estimate Std. Error z value Pr(>|z|)
```

```
ma1 -0.648107 0.083503 -7.7615 8.393e-15 ***
```

```

ma2 0.424589 0.105955 4.0073 6.143e-05 ***
sma1 -1.239020 0.199702 -6.2043 5.492e-10 ***
sma2 0.243520 0.168591 1.4444 0.1486
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```

> summary(arima11)

Series: veri_ts

ARIMA(0,1,2)(0,2,2)[12]

Coefficients:

ma1  ma2  sma1  sma2
-0.6481 0.4246 -1.2390 0.2435
s.e. 0.0835 0.1060 0.1997 0.1686

sigma^2 = 53.01: log likelihood = -448.6
AIC=907.2 AICc=907.7 BIC=921.38

Training set error measures:

ME  RMSE  MAE  MPE  MAPE  MASE
Training set 0.3680018 6.544404 4.40783 0.2588036 4.244286 0.570452

ACF1

Training set -0.09622507

```

Elde edilen çıktıya göre $ma1$, $ma2$ ve $sma1$ katsayılarının önemli ($p < 0.05$) ancak $sma2$ katsayısının önemsiz olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(0,1,2)(0,2,2)_{12}$ modelinin anlamsız olduğu söylenebilir.

$ARIMA(0, 1, 2)(1, 2, 1)_{12}$

H_0 : $ARIMA(0,1,2)(1,2,1)_{12}$ modeli anlamsızdır.

H_s : $ARIMA(0,1,2)(1,2,1)_{12}$ modeli anlamlıdır.

```

z test of coefficients:

Estimate Std. Error z value Pr(>|z|)
ma1 -0.617022 0.079103 -7.8002 6.181e-15 ***
ma2 0.402602 0.104681 3.8460 0.0001201 ***
sar1 -0.110310 0.103472 -1.0661 0.2863842

```

```
sma1 -0.995535 0.094305 -10.5565 < 2.2e-16 ***
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> summary(arima13)
```

Series: veri_ts

ARIMA(0,1,2)(1,2,1)[12]

Coefficients:

ma1 ma2 sar1 sma1

-0.6170 0.4026 -0.1103 -0.9955

s.e. 0.0791 0.1047 0.1035 0.0943

sigma^2 = 55.31: log likelihood = -449.18

AIC=908.37 AICc=908.87 BIC=922.55

Training set error measures:

ME RMSE MAE MPE MAPE MASE

Training set 0.3531003 6.685102 4.432947 0.2579965 4.268031 0.5737027

ACF1

Training set -0.08731271

Elde edilen çıktıya göre ma1, ma2 ve sma1 katsayılarının önemli ($p < 0.05$) ancak sar1 katsayısının önemsiz ($p > 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(0,1,2)(1,2,1)_{12}$ modelinin anlamsız olduğu söylenebilir.

$ARIMA(0, 1, 2)(1, 2, 0)_{12}$

Ho: $ARIMA(0,1,2)(1,2,0)_{12}$ modeli anlamsızdır.

Hs: $ARIMA(0,1,2)(1,2,0)_{12}$ modeli anlamlıdır.

z test of coefficients:

Estimate Std. Error z value Pr(>|z|)

ma1 -0.529152 0.079287 -6.6739 2.491e-11 ***

ma2 0.350218 0.104010 3.3672 0.0007595 ***

sar1 -0.440045 0.084370 -5.2157 1.831e-07 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

> summary(arima12)

Series: veri_ts

ARIMA(0,1,2)(1,2,0)[12]

Coefficients:
      ma1      ma2      sar1
-0.5292  0.3502 -0.4400
s.e.  0.0793  0.1040  0.0844

sigma^2 = 95.24: log likelihood = -469.67
AIC=947.34 AICc=947.67 BIC=958.68

Training set error measures:

ME  RMSE  MAE  MPE  MAPE  MASE
Training set 0.1715759 8.808042 5.983193 0.1597704 5.731926 0.7743322

ACF1
Training set -0.07460106

```

Elde edilen çıktıya göre $ma1$, $ma2$ ve $sar1$ katsayılarının önemli ($p < 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(0,1,2)(1,2,0)_{12}$ modelinin anlamlı olduğu söylenebilir.

RMSE = 8.808042 ve BIC = 958.68 olarak elde edilmiştir. Birden fazla anlamlı model olması durumunda bu bilgi kriterleri ile model seçilecektir.

$ARIMA(0, 1, 2)(2, 2, 0)_{12}$

H_0 : $ARIMA(0,1,2)(2,2,0)_{12}$ modeli anlamsızdır.

H_s : $ARIMA(0,1,2)(2,2,0)_{12}$ modeli anlamlıdır.

```

z test of coefficients:

Estimate Std. Error z value Pr(>|z|)
ma1 -0.697292  0.080157 -8.6991 < 2.2e-16 ***
ma2  0.525318  0.102170  5.1416 2.724e-07 ***
sar1 -0.720216  0.093384 -7.7124 1.235e-14 ***
sar2 -0.497699  0.096028 -5.1829 2.185e-07 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```

> summary(arima14)

Series: veri_ts

ARIMA(0,1,2)(2,2,0)[12]

Coefficients:

ma1  ma2  sar1  sar2
-0.6973  0.5253 -0.7202 -0.4977
s.e.  0.0802  0.1022  0.0934  0.0960

sigma^2 = 76.76: log likelihood = -459.48
AIC=928.97  AICc=929.47  BIC=943.15

Training set error measures:

ME  RMSE  MAE  MPE  MAPE  MASE
Training set 0.2790809 7.874951 5.291612 0.209724 5.082097 0.6848293

ACF1
Training set -0.1013122

```

Elde edilen çıktıya göre $ma1$, $ma2$, $sar1$ ve $sar2$ katsayılarının önemli ($p < 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(0,1,2)(2,2,0)_{12}$ modelinin anlamlı olduğu söylenebilir.

RMSE = 7.874951 ve BIC = 943.15 olarak elde edilmiştir. Birden fazla anlamlı model olması durumunda bu bilgi kriterleri ile model seçilecektir.

$ARIMA(1, 1, 2)(2, 2, 0)_{12}$

H_0 : $ARIMA(1,1,2)(2,2,0)_{12}$ modeli anlamsızdır.

H_s : $ARIMA(1,1,2)(2,2,0)_{12}$ modeli anlamlıdır.

z test of coefficients:

```

Estimate Std. Error z value Pr(>|z|)

ar1 -0.461136  0.151262 -3.0486 0.002299 **
ma1 -0.345007  0.157461 -2.1911 0.028448 *
ma2  0.288748  0.128830  2.2413 0.025005 *
sar1 -0.776900  0.091324 -8.5071 < 2.2e-16 ***
sar2 -0.503254  0.092895 -5.4175 6.045e-08 ***

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
> summary(arima17)
```

Series: veri_ts

ARIMA(1,1,2)(2,2,0)[12]

Coefficients:

ar1 ma1 ma2 sar1 sar2

-0.4611 -0.3450 0.2887 -0.7769 -0.5033

s.e. 0.1513 0.1575 0.1288 0.0913 0.0929

sigma^2 = 73.27: log likelihood = -456.38

AIC=924.76 AICc=925.47 BIC=941.78

Training set error measures:

ME RMSE MAE MPE MAPE MASE

Training set 0.3344319 7.662337 5.165477 0.245304 4.990768 0.6685052

ACF1

Training set -0.01261715

Elde edilen çıktıya göre ar1, ma1, ma2, sar1 ve sar2 katsayılarının önemli ($p < 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(1,1,2)(2,2,0)_{12}$ modelinin anlamlı olduğu söylenebilir.

RMSE = 7.662337 ve BIC = 941.78 olarak elde edilmiştir. Birden fazla anlamlı model olması durumunda bu bilgi kriterleri ile model seçilecektir.

$ARIMA(0, 1, 2)(3, 2, 0)_{12}$

Ho: $ARIMA(0,1,2)(3,2,0)_{12}$ modeli anlamsızdır.

Hs: $ARIMA(0,1,2)(3,2,0)_{12}$ modeli anlamlıdır.

z test of coefficients:

Estimate Std. Error z value Pr(>|z|)

ma1 -0.671740 0.088035 -7.6304 2.340e-14 ***

ma2 0.510299 0.106992 4.7695 1.847e-06 ***

```

sar1 -0.863610 0.109341 -7.8983 2.826e-15 ***
sar2 -0.704882 0.119437 -5.9017 3.597e-09 ***
sar3 -0.340802 0.106401 -3.2030 0.00136 **

---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```
> summary(arima15)
```

Series: veri_ts

ARIMA(0,1,2)(3,2,0)[12]

Coefficients:

```

ma1  ma2  sar1  sar2  sar3
-0.6717 0.5103 -0.8636 -0.7049 -0.3408
s.e. 0.0880 0.1070 0.1093 0.1194 0.1064

```

sigma^2 = 70.11: log likelihood = -454.94

AIC=921.89 AICc=922.59 BIC=938.9

Training set error measures:

```
ME  RMSE  MAE  MPE  MAPE  MASE
```

```
Training set 0.2785585 7.495294 4.97659 0.1969494 4.781319 0.6440598
```

ACF1

Training set -0.1056912

Elde edilen çıktıya göre ma1, ma2, sar1, sar2 ve sar3 katsayılarının önemli ($p < 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(0,1,2)(3,2,0)_{12}$ modelinin anlamlı olduğu söylenebilir.

RMSE = 7.495294 ve BIC = 938.9 olarak elde edilmiştir. Birden fazla anlamlı model olması durumunda bu bilgi kriterleri ile model seçilecektir.

$ARIMA(0, 1, 2)(0, 2, 0)_{12}$

Ho: $ARIMA(0,1,2)(0,2,0)_{12}$ modeli anlamsızdır.

Hs: $ARIMA(0,1,2)(0,2,0)_{12}$ modeli anlamlıdır.

z test of coefficients:

```
Estimate Std. Error z value Pr(>|z|)
```

```
ma1 -0.46189 0.08018 -5.7607 8.379e-09 ***
```

```
ma2 0.28759 0.10496 2.7400 0.006144 **
```

```
---
```

```
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
> summary(arima9)
```

```
Series: veri_ts
```

```
ARIMA(0,1,2)(0,2,0)[12]
```

```
Coefficients:
```

```
ma1 ma2
```

```
-0.4619 0.2876
```

```
s.e. 0.0802 0.1050
```

```
sigma^2 = 115.9: log likelihood = -481.21
```

```
AIC=968.43 AICc=968.63 BIC=976.94
```

```
Training set error measures:
```

```
ME RMSE MAE MPE MAPE MASE
```

```
Training set 0.1636029 9.756629 6.760998 0.1828535 6.508904 0.8749941
```

```
ACF1
```

```
Training set -0.02981973
```

Elde edilen çıktıya göre $ma1$ ve $ma2$ katsayılarının önemli ($p < 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(0,1,2)(0,2,0)_{12}$ modelinin anlamlı olduğu söylenebilir.

RMSE = 9.756629 ve BIC = 976.94 olarak elde edilmiştir. Birden fazla anlamlı model olması durumunda bu bilgi kriterleri ile model seçilecektir.

Hem ACF hem de PACF grafiklerinin yavaş azaldığı durumda seriye uygun model Otoregresif Hareketli Ortalama (ARMA) modelidir. PACF grafiğinde sadece ilk gecikmeye ait ilişki önemli olduğundan $p=1$ 'dir. İki kez mevsimsel fark alındığından $D=2$, bir kez trend için fark alındığından $d=1$ 'dir. ACF grafiğinde ilk iki gecikmeye ait ilişki önemli olduğundan $q=2$ 'dir. Periyodun etrafındaki gecikmelerde önemli bir ilişki olduğundan $P=1$ olarak; Periyodun etrafındaki gecikmeler aynı yönlü olduğundan $Q=1$ olarak düşünülür ancak denemeden kesin bir yargıya varılamaz.

İlk aşamada seriye uygun model $ARIMA(1,1,2)(1,2,1)_{12}$ olmaktadır.

$ARIMA(1, 1, 2)(1, 2, 1)_{12}$

H_0 : $ARIMA(1,1,2)(1,2,1)_{12}$ modeli anlamsızdır.

Hs: $ARIMA(1,1,2)(1,2,1)_{12}$ modeli anlamlıdır.

z test of coefficients:

```
Estimate Std. Error z value Pr(>|z|)
ar1 -0.426976 0.169685 -2.5163 0.01186 *
ma1 -0.285607 0.166181 -1.7187 0.08568 .
ma2 0.207772 0.142876 1.4542 0.14589
sar1 -0.153521 0.102295 -1.5008 0.13342
sma1 -0.995183 0.097893 -10.1660 < 2e-16 ***
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
> summary(arima16)
```

Series: veri_ts

$ARIMA(1,1,2)(1,2,1)[12]$

Coefficients:

```
ar1  ma1  ma2  sar1  sma1
-0.4270 -0.2856 0.2078 -0.1535 -0.9952
s.e. 0.1697 0.1662 0.1429 0.1023 0.0979
```

$\sigma^2 = 53.28$: log likelihood = -446.8

AIC=905.61 AICc=906.31 BIC=922.62

Training set error measures:

```
ME  RMSE  MAE  MPE  MAPE  MASE
```

Training set 0.4091995 6.534199 4.352797 0.2998169 4.20845 0.5633298

ACF1

Training set -0.01609024

Elde edilen çıktıya göre ar1 ve sma1 katsayılarının önemli ($p < 0.05$) ancak ma1, ma2 ve sar1 katsayıları önemsiz ($p > 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(1,1,2)(1,2,1)_{12}$ modelinin anlamsız olduğu söylenebilir.

Tüm aday modeller için öncelikle katsayıların anlamlılığına ve bilgi kriterlerine bakılmıştır. Sonrasında, katsayıları anlamlı çıkan modeller için Rstudio’da ACF ve PACF grafikleri

incelenmiştir, ilk 20 gecikmeye ait değerler liste halinde kontrol edilmiştir ve Box Testi sonuçlarına bakılmıştır. Yapılan işlemlere ait kodlar çalışmada yer almaktadır. Modellerin elde edilen tüm bu sonuçları aşağıdaki tabloda özetlenmiştir.

Model	BIC Değeri	İlk 20 Gecikmedeki Durum	Box Testi P Değeri
ARIMA(1,1,2)(2,2,0)	941.78	0 adet anlamlı	0.052
ARIMA(1,1,0)(0,2,1)	912.41	1 adet anlamlı	0.026
ARIMA(0,1,2)(0,2,1)	918.80	3 adet anlamlı	0.003
ARIMA(1,1,0)(3,2,0)	933.80	2 adet anlamlı	0.003
ARIMA(1,1,0)(2,2,0)	937.58	1 adet anlamlı	0.008
ARIMA(0,1,2)(3,2,0)	938.90	1 adet anlamlı	0.0006
ARIMA(0,1,2)(2,2,0)	943.15	3 adet anlamlı	0.006
ARIMA(1,1,0)(1,2,0)	949.43	2 adet anlamlı	0.000
ARIMA(0,1,2)(1,2,0)	958.60	3 adet anlamlı	0.00001
ARIMA(1,1,0)(0,2,0)	972.60	2 adet anlamlı	0.000
ARIMA(0,1,2)(0,2,0)	976.90	2 adet anlamlı	0.000

ARIMA(1,1,2)(2,2,0) modeli; hem katsayılarının anlamlı olması hem de Box Testi sonucunda p-değerinin 0.05'ten büyük çıkması (hataların akgürültü olması) nedeniyle varsayımları sağlayan tek model olarak belirlenmiştir. Bu sebeple, öngörü aşamasında ARIMA(1,1,2)(2,2,0) modelinin kullanılmasına karar verilmiştir.

ARIMA(1, 1, 2)(2, 2, 0)₁₂

Ho: ARIMA(1,1,2)(2,2,0)₁₂ modeli anlamsızdır.

Hs: ARIMA(1,1,2)(2,2,0)₁₂ modeli anlamlıdır.

z test of coefficients:

```

      Estimate Std. Error z value Pr(>|z|)
ar1 -0.461136  0.151262 -3.0486 0.002299 **
ma1 -0.345007  0.157461 -2.1911 0.028448 *
ma2  0.288748  0.128830  2.2413 0.025005 *
sar1 -0.776900  0.091324 -8.5071 < 2.2e-16 ***
sar2 -0.503254  0.092895 -5.4175 6.045e-08 ***

---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```
> summary(arima17)
```

```
Series: veri_ts
```

```
ARIMA(1,1,2)(2,2,0)[12]
```

```
Coefficients:
```

```

ar1  ma1  ma2  sar1  sar2
-0.4611 -0.3450 0.2887 -0.7769 -0.5033
s.e. 0.1513 0.1575 0.1288 0.0913 0.0929

```

```
sigma^2 = 73.27: log likelihood = -456.38
```

```
AIC=924.76 AICc=925.47 BIC=941.78
```

```
Training set error measures:
```


```
ME  RMSE  MAE  MPE  MAPE  MASE
```

```
Training set 0.3344319 7.662337 5.165477 0.245304 4.990768 0.6685052
```


```
ACF1
```

```
Training set -0.01261715
```

Elde edilen çıktıya göre ar1, ma1, ma2, sar1 ve sar2 katsayılarının önemli ($p < 0.05$) olduğu söylenebilir. %95 Güven düzeyinde $ARIMA(1,1,2)(2,2,0)_{12}$ modelinin anlamlı olduğu söylenebilir. RMSE = 7.662337 ve BIC = 941.78 olarak elde edilmiştir.



Grafiğe bakıldığında orijinal seri ile tahmin serisinin genel olarak uyumlu olduğu görülmektedir.



Bazı gecikmelerin sınır dışının biraz dışında olduğu görülmektedir. İlk 20 gecikmeler incelendiğinde tüm gecikmelerin anlamsız olduğu görülmüştür.

Box – Ljung Testi:

Ho: Hatalar arasında ilişki yoktur.

Hs: Hatalar arasında ilişki vardır.

Box-Ljung test

data: hata17

X-squared = 29.943, df = 19, p-value = 0.05253


Box – Ljung testine göre hatalar arasında ilişki olmadığı %95 güven düzeyinde söylenir. Sonuç olarak hata serisinin akgürültü olduğu ve $ARIMA(1,1,2)(2,2,0)_{12}$ modelinin seri için istatistiksel olarak geçerli olduğu söylenebilir.

6.2 Öngörü

Serinin 5 öngörüsü aşağıdaki şekilde elde edilmiştir. Elde edilen öngörüler ile orijinal serinin benzerlik gösterdiği söylenebilir.

	Donem	Ongoru_Degeri
1	2018-01	105.16
2	2018-02	109.39
3	2018-03	123.69
4	2018-04	120.77
5	2018-05	125.39

	Donem_Gercek	Gercek_Deger
1	2017-03	118.85
2	2017-04	114.89
3	2017-05	118.46
4	2017-06	103.16
5	2017-07	109.74
6	2017-08	110.52
7	2017-09	106.58
8	2017-10	122.93
9	2017-11	122.14
10	2017-12	117.37



Grafikte siyah çizgi, 2005-2017 yılları arasındaki gerçek sanayi üretim endeksi verilerini; mavi çizgi ise ARIMA modeli ile elde edilen 2018 yılına ait öngörülerini (forecast) göstermektedir.

Mavi tahmin çizgisinin, geçmiş verilerdeki (siyah çizgi) mevsimsel dalgalanmalarla uyumlu hareket ettiği görülmektedir. Ayrıca tahmin edilen değerlerin etrafındaki gölgeli alanlar (Güven Aralıkları), öngörüdeki belirsizlik payını temsil etmektedir. Tahmin döneminin kısıllığı nedeniyle güven aralığının dar olması, modelin kısa vadeli tahminlerde güvenilir olduğunu işaret etmektedir.

7. Kodlar

```
install.packages("forecast")
install.packages("readxl")
library(forecast)
library(readxl)

data <- read_excel("C:/Users/zehra/OneDrive - hacettepe.edu.tr/Masaüstü/EVDS.xlsx")
summary(data)

# Zaman Serisi oluşturma
veri_vektor <- data[[1]]
veri_ts <- ts(veri_vektor, start=c(2005, 6), frequency=12)
print(veri_ts)

# Orijinal Serinin Grafikleri
# Zaman Serisi Grafiği
ts.plot(veri_ts, gpars=list(xlab="Zaman", ylab="Değerler", main="EVDS Verisi Zaman Serisi"),
        lwd=2, col="blue")
Acf(veri_ts, lag.max = 42, main="Orijinal Seri ACF Grafiği", ylim=c(-1,1), lwd=3)
Pacf(veri_ts, lag.max = 42, main="Orijinal Seri PACF Grafiği", ylim=c(-1,1), lwd=3)

# DURAĞANLAŞTIRMA (FARK ALMA İŞLEMLERİ)
# Trent için 1. Dereceden Fark Alma
veri_diff <- diff(veri_ts)

# Farkı alınmış serinin grafiği
ts.plot(veri_diff,
        gpars=list(xlab="Zaman", ylab="Fark Değerleri", main="1. Dereceden Farkı Alınmış Seri"),
        lwd=2, col="red")
abline(h=0, col="blue", lty=2) # Referans çizgisi

# Trend farkı sonrası ACF/PACF
```

```
Acf(veri_diff, lag.max = 42, main="1. Trent Farkı Alınmış Serinin ACF Grafiği", ylim=c(-1,1), lwd=3)
```

```
Pacf(veri_diff, lag.max = 42, main="1. Tren Farkı Alınmış Serinin PACF Grafiği", ylim=c(-1,1), lwd=3)
```

```
# Mevsimsellik İçin 1. Dereceden Fark Alma
```

```
veri_mevsim_fark_1 <- diff(veri_diff, lag = 12)
```

```
ts.plot(veri_mevsim_fark_1,  
        main="Trend + 1. Mevsimsel Farkı Alınmış Seri",  
        ylab="Değer", col="blue")  
abline(h=0, col="red", lty=2)
```

```
Acf(veri_mevsim_fark_1, lag.max = 48, main="ACF (1. Trent + 1. Mevsimsel Fark)", lwd=3)
```

```
Pacf(veri_mevsim_fark_1, lag.max = 48, main="PACF (1. Trent + 1. Mevsimsel Fark)", lwd=3)
```

```
# Mevsimsellik İçin 2. Dereceden Fark Alma
```

```
veri_mevsim_fark_2 <- diff(veri_mevsim_fark_1, lag = 12)
```

```
ts.plot(veri_mevsim_fark_2,  
        main="Trend + 2 Kez Mevsimsel Fark Alınmış Seri",  
        ylab="Değer", col="darkgreen", lwd=2)  
abline(h=0, col="red", lty=2)
```

```
Acf(veri_mevsim_fark_2, lag.max = 48, main="ACF (1. Trent + 2. Mevsimsel Fark)", lwd=3)
```

```
Pacf(veri_mevsim_fark_2, lag.max = 48, main="PACF (1. Trent + 2. Mevsimsel Fark)", lwd=3)
```

```
##### AYRIŞTIRMA YÖNTEMLERİ #####
```

```
# HAREKETLİ ORTALAMA (MA) YÖNTEMİ
```

```
data2_ts <- ma(veri_ts, order = 12, centre = TRUE)
```

```
par(mar = c(5, 4, 6, 2), xpd = TRUE)
```

```
plot(window(veri_ts),
```

```

xlab="Zaman",
ylab="Değer",
lty=1, col=4, lwd=1,
main="Hareketli Ortalama")
lines(window(data2_ts), lty=3, col=2, lwd=2)
legend("topleft",
      c("Gerçek Veri", "MA(12)"),
      lwd=c(2,2),
      lty=c(1,3),
      cex=0.7,
      col=c(4,2),
      inset = c(0, -0.25),
      bty = "n")

# TOPLAMSAL AYRIŞTIRMA MODELİ
# Trendi Bulma (tslm)
data_trent <- tslm(veri_ts ~ trend)
periyot <- veri_ts - data_trent[["fitted.values"]]

# Mevsimselliği Ayıklama (Veri - MA)
mevsim <- veri_ts - data2_ts

# Mevsimsel İndekslerin Hesabı (Matris - Aylık)
# Veri uzunluğunu güvenli hale getirme (Hata vermemesi için)
len <- length(mevsim)
if(len %% 12 != 0) {
  mevsim_vec <- c(mevsim, rep(NA, 12 - (len %% 12)))
} else {
  mevsim_vec <- mevsim
}

# 12 Aylık Matris

```

```

donemort <- t(matrix(data = mevsim_vec, nrow = 12))
endeks <- colMeans(donemort, na.rm = T) - mean(colMeans(donemort, na.rm = T))

# İndeksleri Seriyeye Yama
indeks <- ts(rep(endeks, length.out = length(veri_ts)), start=start(veri_ts), frequency=12)

# Kontrol
indeks_alternatif <- decompose(veri_ts, "additive")

# Saf Trend, Tahmin ve Hata
trenthata <- veri_ts - indeks
trent <- tslm(trenthata ~ trend)
tahmin <- indeks + trent[["fitted.values"]]
hata <- veri_ts - indeks - trent[["fitted.values"]]

# GRAFİK: Orijinal Seri vs Tahmin
par(mar = c(5, 4, 6, 2), xpd = TRUE)
plot(window(veri_ts),
      xlab="Zaman", ylab="Değer",
      lty=1, col=4, lwd=2,
      main="Toplamsal Ayırıştırma Sonucu")
lines(window(tahmin), lty=3, col=2, lwd=3)
legend("topleft",
      c("Gerçek Veri", "Tahmin"),
      lwd = c(2,2),
      lty = c(1,3),
      col = c(4,2),
      cex = 0.7,
      inset = c(0, -0.25),
      bty = "n")

# Akgürültü kontrolü

```

```

if(!is.null(dev.list())) dev.off()

Acf(hata, main="Toplamsal Model Hataları", lag.max = 42, ylim=c(-1,1), lwd=3)
Pacf(hata, main="Toplamsal Model Hataları", lag.max = 42, ylim=c(-1,1), lwd=3)
Box.test(hata, lag = 24, type = "Ljung-Box")

print(paste("Toplamsal HKO:", sqrt(mean(hata^2, na.rm=T))))

#ÇARPIMSAL AYRIŞTIRMA MODELİ
# Mevsimselliği Ayıklama (BÖLME İŞLEMİ)
mevsim1 <- veri_ts / data2_ts

# Mevsimsel İndekslerin Hesabı (Matris - Aylık)
if(length(mevsim1) %% 12 != 0) {
  mevsim1_vec <- c(mevsim1, rep(NA, 12 - (length(mevsim1) %% 12)))
} else {
  mevsim1_vec <- mevsim1
}

# 12 Aylık Matris
donemort1 <- t(matrix(data = mevsim1_vec, nrow = 12))

# (Çarpımsal Kuralı):
# İndekslerin ortalaması 1 olmalıdır. Bu yüzden ortalamaya BÖLÜYORUZ.
endeks1 <- colMeans(donemort1, na.rm = T) / mean(colMeans(donemort1, na.rm = T))

# İndeksleri Seriye Yayma
# Senin verinin uzunluğuna göre ayarlıyoruz
indeks1 <- ts(rep(endeks1, length.out = length(veri_ts)), start=start(veri_ts), frequency=12)

# Kontrol (decompose fonksiyonu ile)
indeks1_alternatif <- decompose(veri_ts, "multiplicative")

```

```

# Saf Trend, Tahmin ve Hata

# Trendi bulmak için veriyi indekse bölünür
trenthata1 <- veri_ts / indeks1
trent1 <- tslm(trenthata1 ~ trend)

# Tahmin = İndeks * Trend (ÇARPMA)
tahmin1 <- indeks1 * trent1[["fitted.values"]]

# Hata = Gerçek - Tahmin (Karşılaştırma için fark alıyoruz)
hata1 <- veri_ts - tahmin1

# Grafik çizimi
if(!is.null(dev.list())) dev.off()

par(mar = c(5, 4, 6, 2), xpd = TRUE)
plot(window(veri_ts),
      xlab="Zaman", ylab="Değer",
      lty=1, col=4, lwd=2,
      main="Çarpımsal Ayırıştırma Sonucu")
lines(window(tahmin1), lty=3, col=2, lwd=3)
legend("topleft",
      c("Gerçek Veri", "Tahmin"),
      lwd = c(2,2),
      lty = c(1,3),
      col = c(4,2),
      cex = 0.7,
      inset = c(0, -0.25),
      bty = "n")

if(!is.null(dev.list())) dev.off()

# Hatalar Akgürültü mü?
Acf(hata1, main="Çarpımsal Model Hataları (ACF)", lag.max = 42, ylim=c(-1,1), lwd=3)

```

```

Pacf(hata1, main="Çarpımsal Model Hataları (PACF)", lag.max = 42, ylim=c(-1,1), lwd=3)
Box.test(hata1, lag = 24, type = "Ljung-Box")
print(paste("Çarpımsal HKO:", sqrt(mean(hata1^2, na.rm=T))))

##### Regresyon Analizi #####
#DÖNÜŞTÜRME (Box-Cox Transformation)
# Lambda parametresini otomatik buluyoruz
lambda_degeri <- BoxCox.lambda(veri_ts)
print(paste("Bulunan Lambda Değeri:", round(lambda_degeri, 4)))
veri_donusumlu <- BoxCox(veri_ts, lambda_degeri)
# Dönüşmüş verinin grafiği
plot(veri_donusumlu, main="Box-Cox Dönüşümü Yapılmış Seri", ylab="Dönüşümlü Değerler",
col="darkblue")

# TOPLAMSAL MODEL #
n <- length(veri_donusumlu)
t <- 1:n

sin1 <- sin(2 * pi * t / 12)
cos1 <- cos(2 * pi * t / 12)

sin2 <- sin(2 * pi * 2 * t / 12)
cos2 <- cos(2 * pi * 2 * t / 12)

veriseti_reg <- data.frame(y = as.numeric(veri_donusumlu), t = t,
                           sin1 = sin1, cos1 = cos1,
                           sin2 = sin2, cos2 = cos2)

# Model 1: Sadece t, sin1, cos1
regresyon_model1 <- lm(y ~ t + sin1 + cos1, data = veriseti_reg)
summary(regresyon_model1)

```

```

# Model 2: t, sin1, cos1 + sin2, cos2
regresyon_model2 <- lm(y ~ t + sin1 + cos1 + sin2 + cos2, data = veriseti_reg)
summary(regresyon_model2)

#TAHMİN VE GRAFİK (Model 2 İçin)
secilen_model <- regresyon_model2

# Tahmin ve Güven Aralıkları
tahmin_tum <- predict(secilen_model, interval="confidence", level=0.95)

# Geri Dönüştürme
tahmin_gercek <- InvBoxCox(tahmin_tum[, "fit"], lambda_degeri)
alt_sinir <- InvBoxCox(tahmin_tum[, "lwr"], lambda_degeri)
ust_sinir <- InvBoxCox(tahmin_tum[, "upr"], lambda_degeri)

# Zaman serisi formatına çevirme
tahmin_serisi <- ts(tahmin_gercek, start=start(veri_ts), frequency=12)
alt_sinir_serisi <- ts(alt_sinir, start=start(veri_ts), frequency=12)
ust_sinir_serisi <- ts(ust_sinir, start=start(veri_ts), frequency=12)

if(!is.null(dev.list())) dev.off()
par(mar = c(5, 4, 7, 2), xpd = TRUE)
plot(veri_ts,
     main="Regresyon (Model 2)",
     ylab="Değer", lwd=1, col="black")
lines(alt_sinir_serisi, col="blue", lwd=1, lty=1)
lines(ust_sinir_serisi, col="blue", lwd=1, lty=1)
legend("topleft",
     legend=c("Gerçek Veri", "%95 Güven Aralığı"),
     col=c("black", "blue"),
     lty=c(1,1),
     lwd=c(1,1),

```

```

inset=c(0, -0.40),
bty="n", cex=0.8)

hata_reg <- veri_ts - tahmin_serisi
# Durbin-Watson Testi (Otokorelasyon Kontrolü)
install.packages("lmtest")
library(lmtest)
print("Durbin-Watson Testi")
dwtest(secilen_model)

library(forecast)
if(!is.null(dev.list())) dev.off()
Acf(hata_reg, main="Model 2 Hataları (ACF)", lag.max=36, lwd=3)
Pacf(hata_reg, main="Model 2 Hataları (PACF)", lag.max=36, lwd=3)

print("--- Box-Ljung Testi ---")
Box.test(hata_reg, lag=24, type="Ljung-Box")

HKO_regresyon <- sqrt(mean(hata_reg^2, na.rm=T))
print(paste("Regresyon (Model 2) HKO Değeri:", round(HKO_regresyon, 4)))

# ÇarpıMSAL MODEL #
library(forecast)
library(lmtest)

n <- length(veri_donusumlu)
t <- 1:n

# 1. Harmonikler (Çarpımsal)
sin1_c <- t * sin(2 * pi * t / 12)
cos1_c <- t * cos(2 * pi * t / 12)

```

```

veriseti_carpim1 <- data.frame(y = as.numeric(veri_donusumlu), t = t,
                               sin1_c = sin1_c, cos1_c = cos1_c)

# Model 1'i Kurma
model_carpimsal1 <- lm(y ~ t + sin1_c + cos1_c, data = veriseti_carpim1)
print("ÇARPIMSAL MODEL 1 ÖZETİ")
summary(model_carpimsal1)

# 2. Harmonikler (Çarpımsal)
sin2_c <- t * sin(2 * pi * 2 * t / 12)
cos2_c <- t * cos(2 * pi * 2 * t / 12)

veriseti_carpim2 <- data.frame(y = as.numeric(veri_donusumlu), t = t,
                               sin1_c = sin1_c, cos1_c = cos1_c,
                               sin2_c = sin2_c, cos2_c = cos2_c)

model_carpimsal2 <- lm(y ~ t + sin1_c + cos1_c + sin2_c + cos2_c, data = veriseti_carpim2)

print("ÇARPIMSAL MODEL 2 ÖZETİ")
summary(model_carpimsal2)

secilen_model_carpim <- model_carpimsal2

# Tahmin ve güven aralıkları
tahmin_tum_c <- predict(secilen_model_carpim, interval="confidence", level=0.95)

# Geri dönüştürme
tahmin_gercek_c <- InvBoxCox(tahmin_tum_c[, "fit"], lambda_degeri)
alt_sinir_c <- InvBoxCox(tahmin_tum_c[, "lwr"], lambda_degeri)
ust_sinir_c <- InvBoxCox(tahmin_tum_c[, "upr"], lambda_degeri)

```

```

# Zaman Serisi Formatı

tahmin_serisi_c <- ts(tahmin_gercek_c, start=start(veri_ts), frequency=12)
alt_sinir_serisi_c <- ts(alt_sinir_c, start=start(veri_ts), frequency=12)
ust_sinir_serisi_c <- ts(ust_sinir_c, start=start(veri_ts), frequency=12)

if(!is.null(dev.list())) dev.off()

par(mar = c(5, 4, 7, 2), xpd = TRUE)

plot(veri_ts,
     main="Çarpımsal Regresyon (Model 2)",
     ylab="Değer", lwd=1, col="black")

# Güven Sınırları

lines(alt_sinir_serisi_c, col="blue", lwd=1, lty=1)
lines(ust_sinir_serisi_c, col="blue", lwd=1, lty=1)

legend("topleft",
     legend=c("Gerçek Veri", "%95 Güven Aralığı"),
     col=c("black", "blue"),
     lty=c(1,1), lwd=c(1,1),
     inset=c(0, -0.40), # Kutuyu yukarı taşı
     bty="n", cex=0.8)

hata_carpim <- veri_ts - tahmin_serisi_c

# Durbin-Watson Testi

print("--- Durbin-Watson (Çarpımsal) ---")
dwtest(secilen_model_carpim)

if(!is.null(dev.list())) dev.off()

Acf(hata_carpim, main="Çarpımsal Model Hataları (ACF)", lag.max=36, lwd=3)
Pacf(hata_carpim, main="Çarpımsal Model Hataları (PACF)", lag.max=36, lwd=3)

```

```
Box.test(hata_carpim, lag=24, type="Ljung-Box")
```

```
HKO_carpim_reg <- sqrt(mean(hata_carpim^2, na.rm=T))
```

```
print(paste("Çarpımsal Regresyon HKO Değeri:", round(HKO_carpim_reg, 4)))
```

```
##### ÜSTEL DÜZLEŞTİRME YÖNTEMİ #####
```

```
## TOPLAMSAL WINTERS YÖNTEMİ ##
```

```
library(forecast)
```

```
winters_toplamsal <- ets(veri_ts, model = "AAA")
```

```
summary(winters_toplamsal)
```

```
tahmin_winters_top <- winters_toplamsal[["fitted"]]
```

```
if(!is.null(dev.list())) dev.off()
```

```
par(mar = c(5, 4, 4, 2))
```

```
plot(window(veri_ts),
```

```
  xlab="Zaman", ylab="Değer",
```

```
  main="Toplamsal Winters Metodu (AAA)",
```

```
  lty=1, col="black", lwd=2)
```

```
lines(window(tahmin_winters_top), lty=2, col="red", lwd=2)
```

```
hata_winters_top <- winters_toplamsal[["residuals"]]
```

```
Box.test(hata_winters_top, lag = 24, type = "Ljung-Box")
```

```
if(!is.null(dev.list())) dev.off()
```

```
Acf(hata_winters_top, main="Toplamsal Winters Hataları (ACF)", lag.max=36, lwd=3)
```

```
Pacf(hata_winters_top, main="Toplamsal Winters Hataları (PACF)", lag.max=36, lwd=3)
```

```
## ÇARPIMSAL WINTERS YÖNTEMİ ##
```

```
winters_carpimsal <- ets(abs(veri_ts), model = "MAM")
```

```
summary(winters_carpimsal)
```

```

tahmin_winters_c <- winters_carpimsal[["fitted"]]

if(!is.null(dev.list())) dev.off()

par(mar = c(5, 4, 4, 2))

plot(window(veri_ts),
      xlab="Zaman", ylab="Değer",
      main="Çarpımsal Winters Metodu (MAM)",
      lty=1, col="black", lwd=2)
lines(window(tahmin_winters_c), lty=2, col="red", lwd=2)

hata_winters_c <- winters_carpimsal[["residuals"]]
Box.test(hata_winters_c, lag = 24, type = "Ljung-Box")
if(!is.null(dev.list())) dev.off()
Acf(hata_winters_c, main="Çarpımsal Winters Hataları (ACF)", lag.max=36, lwd=3, ylim=c(-1,1))
Pacf(hata_winters_c, main="Çarpımsal Winters Hataları (PACF)", lag.max=36, lwd=3, ylim=c(-1,1))

##### BOX JENKINS MODELLERİ #####

install.packages("forecast")
install.packages("readxl")
library(forecast)
library(readxl)

# seriyi Yükleme
data <- read_excel("C:/Users/zehra/OneDrive - hacettepe.edu.tr/Masaüstü/EVDS.xlsx")

# Zaman Serisi oluşturma
veri_vektor <- data[[1]]
veri_ts <- ts(veri_vektor, start=c(2005, 6), frequency=12)

# Veriyi kontrol etme
print(veri_ts)

```

```

# Orijinal Serinin Grafikleri

ts.plot(veri_ts, gpars=list(xlab="Zaman", ylab="Değerler", main="EVDS Verisi Zaman Serisi"),
        lwd=2, col="blue")

Acf(veri_ts, lag.max = 42, main="Orijinal Seri ACF Grafiği", ylim=c(-1,1), lwd=3)
Pacf(veri_ts, lag.max = 42, main="Orijinal Seri PACF Grafiği", ylim=c(-1,1), lwd=3)

# DURAĞANLAŞTIRMA (FARK ALMA İŞLEMLERİ)

# Trent için 1. Dereceden Fark Alma
veri_diff <- diff(veri_ts)

# Farkı alınmış serinin grafiği
ts.plot(veri_diff,
        gpars=list(xlab="Zaman", ylab="Fark Değerleri", main="1. Dereceden Farkı Alınmış Seri"),
        lwd=2, col="red")
abline(h=0, col="blue", lty=2)

# Trend farkı sonrası ACF/PACF
Acf(veri_diff, lag.max = 42, main="1. Trent Farkı Alınmış Serinin ACF Grafiği", ylim=c(-1,1),
    lwd=3)
Pacf(veri_diff, lag.max = 42, main="1. Tren Farkı Alınmış Serinin PACF Grafiği", ylim=c(-1,1),
    lwd=3)

# Mevsimsellik İçin 1. Dereceden Fark Alma
veri_mevsim_fark_1 <- diff(veri_diff, lag = 12)

ts.plot(veri_mevsim_fark_1,
        main="Trend + 1. Mevsimsel Farkı Alınmış Seri",
        ylab="Değer", col="blue")
abline(h=0, col="red", lty=2)

# ACF ve PACF
Acf(veri_mevsim_fark_1, lag.max = 48, main="ACF (1. Trent + 1. Mevsimsel Fark)", lwd=3)

```

```
Pacf(veri_mevsim_fark_1, lag.max = 48, main="PACF (1. Trent + 1. Mevsimsel Fark)", lwd=3)
```

```
# Mevsimsellik İçin 2. Dereceden Fark Alma
```

```
veri_mevsim_fark_2 <- diff(veri_mevsim_fark_1, lag = 12)
```

```
ts.plot(veri_mevsim_fark_2,  
        main="Trend + 2 Kez Mevsimsel Fark Alınmış Seri",  
        ylab="Değer", col="darkgreen", lwd=2)  
abline(h=0, col="red", lty=2)
```

```
# ACF ve PACF
```

```
Acf(veri_mevsim_fark_2, lag.max = 48, main="ACF (1. Trent + 2. Mevsimsel Fark)", lwd=3)
```

```
Pacf(veri_mevsim_fark_2, lag.max = 48, main="PACF (1. Trent + 2. Mevsimsel Fark)", lwd=3)
```

```
## ACF yavaş azalıyor. AR ##
```

```
library(forecast)
```

```
library(lmtest)
```

```
# Model:ARIMA(1,1,0)(1,2,0)
```

```
arima2 <- Arima(veri_ts, order=c(1,1,0), seasonal=c(1,2,0), include.constant=TRUE)
```

```
coeftest(arima2)
```

```
summary(arima2)
```

```
#anlamlı
```

```
hata2 <- residuals(arima2)
```

```
Acf(hata2, main="Hata ACF (Model 2)", lag.max=42, ylim=c(-1,1), lwd=3)
```

```
Pacf(hata2, main="Hata PACF (Model 2)", lag.max=42, ylim=c(-1,1), lwd=3)
```

```
Box.test(hata2, lag=24, type="Ljung-Box", fitdf=2)
```

```
n <- length(hata2)
```

```
sinir_degeri <- 1.96 / sqrt(n)
```

```
acf_data <- Acf(hata2, lag.max=20, plot=FALSE)
```

```

acf_degerleri <- acf_data$acf[2:21] # İlk 20 gecikme

# Sig. (P-Value) Hesaplama
# Formül:  $Z = ACF * \sqrt{n} \rightarrow P = 2 * (1 - pnorm(|Z|))$ 
z_skoru <- acf_degerleri * sqrt(n)
sig_degerleri <- 2 * (1 - pnorm(abs(z_skoru)))

tablo2 <- data.frame(
  Gecikme = 1:20,
  ACF = round(acf_degerleri, 3),
  Limit = round(sinir_degeri, 3),
  Sig_Degeri = round(sig_degerleri, 3),
  Durum = ifelse(sig_degerleri < 0.05,
    "ANLAMLI",
    "Anlamsız")
)
print(tablo2)

# Farklı Kombinasyonlar
# Model: ARIMA(1,1,0)(2,2,0)
arima3 <- Arima(veri_ts, order=c(1,1,0), seasonal=c(2,2,0), include.constant=TRUE)
coefest(arima3)
summary(arima3)
#anlamlı
hata3 <- residuals(arima3)
Acf(hata3, main="Hata ACF (Model 3)", lag.max=42, ylim=c(-1,1), lwd=3)
Pacf(hata3, main="Hata PACF (Model 3)", lag.max=42, ylim=c(-1,1), lwd=3)
Box.test(hata3, lag=24, type="Ljung-Box", fitdf=3)

n <- length(hata3)
sinir_degeri <- 1.96 / sqrt(n)
acf_data <- Acf(hata3, lag.max=20, plot=FALSE)

```

```

acf_degerleri <- acf_data$acf[2:21] # İlk 20 gecikme

# Sig. (P-Value) Hesaplama
# Formül:  $Z = ACF * \sqrt{n} \rightarrow P = 2 * (1 - pnorm(|Z|))$ 
z_skoru <- acf_degerleri * sqrt(n)
sig_degerleri <- 2 * (1 - pnorm(abs(z_skoru)))

tablo3 <- data.frame(
  Gecikme = 1:20,
  ACF = round(acf_degerleri, 3),
  Limit = round(sinir_degeri, 3),
  Sig_Degeri = round(sig_degerleri, 3),
  Durum = ifelse(sig_degerleri < 0.05,
    "ANLAMLI",
    "Anlamsız")
)
print(tablo3)

# Model: ARIMA(1,1,0)(3,2,0)
arima4 <- Arima(veri_ts, order=c(1,1,0), seasonal=c(3,2,0), include.constant=TRUE)
coefest(arima4)
summary(arima4)
#anlamlı
hata4 <- residuals(arima4)
Acf(hata4, main="Hata ACF (Model 4)", lag.max=42, ylim=c(-1,1), lwd=3)
Pacf(hata4, main="Hata PACF (Model 4)", lag.max=42, ylim=c(-1,1), lwd=3)
Box.test(hata4, lag=24, type="Ljung-Box")
checkresiduals(arima4)

n <- length(hata4)
sinir_degeri <- 1.96 / sqrt(n)
acf_data <- Acf(hata4, lag.max=20, plot=FALSE)

```

```

acf_degerleri <- acf_data$acf[2:21] # İlk 20 gecikme

# Sig. (P-Value) Hesaplama
# Formül:  $Z = ACF * \sqrt{n} \rightarrow P = 2 * (1 - pnorm(|Z|))$ 
z_skoru <- acf_degerleri * sqrt(n)
sig_degerleri <- 2 * (1 - pnorm(abs(z_skoru)))

tablo4 <- data.frame(
  Gecikme = 1:20,
  ACF = round(acf_degerleri, 3),
  Limit = round(sinir_degeri, 3),
  Sig_Degeri = round(sig_degerleri, 3),
  Durum = ifelse(sig_degerleri < 0.05,
    "ANLAMLI",
    "Anlamsız")
)
print(tablo4)

# Model: ARIMA(1,1,0)(0,2,0)
arima1 <- Arima(veri_ts, order=c(1,1,0), seasonal=c(0,2,0), include.constant=TRUE)
coeftest(arima1)
summary(arima1)
#anlamlı
hata1 <- residuals(arima1)
Acf(hata1, main="Hata ACF (Model 1)", lag.max=42, ylim=c(-1,1), lwd=3)
Pacf(hata1, main="Hata PACF (Model 1)", lag.max=42, ylim=c(-1,1), lwd=3)
Box.test(hata1, lag=24, type="Ljung-Box", fitdf=1)

n <- length(hata1)
sinir_degeri <- 1.96 / sqrt(n)
acf_data <- Acf(hata1, lag.max=20, plot=FALSE)
acf_degerleri <- acf_data$acf[2:21] # İlk 20 gecikme

```

```

# Sig. (P-Value) Hesaplama
# Formül:  $Z = ACF * \sqrt{n} \rightarrow P = 2 * (1 - pnorm(|Z|))$ 
z_skoru <- acf_degerleri * sqrt(n)
sig_degerleri <- 2 * (1 - pnorm(abs(z_skoru)))

tablo1 <- data.frame(
  Gecikme = 1:20,
  ACF = round(acf_degerleri, 3),
  Limit = round(sinir_degeri, 3),
  Sig_Degeri = round(sig_degerleri, 3),
  Durum = ifelse(sig_degerleri < 0.05,
    "ANLAMLI",
    "Anlamsız")
)
print(tablo1)

# Model: ARIMA(1,1,0)(1,2,1)[12]
arima7 <- Arima(veri_ts, order=c(1,1,0), seasonal=c(1,2,1), include.constant=TRUE)
coeftest(arima7)
summary(arima7)
#anlamsız

# Model: ARIMA(1,1,0)(0,2,1)[12]
arima5 <- Arima(veri_ts, order=c(1,1,0), seasonal=c(0,2,1), include.constant=TRUE)
coeftest(arima5)
summary(arima5)
#anlamlı

hata <- residuals(arima5)
if(!is.null(dev.list())) dev.off()
Acf(hata, main="Hata ACF", lag.max=42, ylim=c(-1,1), lwd=3)
Pacf(hata, main="Hata PACF", lag.max=42, ylim=c(-1,1), lwd=3)

```

```

Box.test(hata, lag=24, type="Ljung-Box")
#İLK 20 GECİKME
hata <- residuals(arima5)
n <- length(hata)
sinir_degeri <- 1.96 / sqrt(n)

acf_data <- Acf(hata, lag.max=20, plot=FALSE)
acf_degerleri <- acf_data$acf[2:21] # 1-20 arasını al

# 3. Sig. (P-Value) Hesaplama Formülü
# SPSS mantığı:  $Z = r * \sqrt{n}$  üzerinden p-değeri hesaplanır.
z_skoru <- acf_degerleri * sqrt(n)
sig_degerleri <- 2 * (1 - pnorm(abs(z_skoru)))

tablo <- data.frame(
  Gecikme = 1:20,
  ACF = round(acf_degerleri, 3),
  Limit = round(sinir_degeri, 3),
  Sig_Degeri = round(sig_degerleri, 3),
  Durum = ifelse(sig_degerleri < 0.05,
    "ANLAMLI",
    "Anlamsız")
)

print(tablo)

# Model: ARIMA(1,1,0)(0,2,2)[12]
arima6 <- Arima(veri_ts, order=c(1,1,0), seasonal=c(0,2,2), include.constant=TRUE)
coeftest(arima6)
summary(arima6)
#anlamsız

```

```

# Model: ARIMA(1,1,0)(2,2,1)[12]
arima8 <- Arima(veri_ts, order=c(1,1,0), seasonal=c(2,2,1), include.constant=TRUE)
coeftest(arima8)
summary(arima8)
#anlamsız

## PACF yavaş azalıyor. MA ##
# Model: ARIMA(0,1,2)(0,2,1)[12]
arima10 <- Arima(veri_ts, order=c(0,1,2), seasonal=c(0,2,1), include.constant=TRUE)
coeftest(arima10)
summary(arima10)
#anlamlı

hata10 <- residuals(arima10)
Acf(hata10, main="Hata ACF (Model 10)", lag.max=42, ylim=c(-1,1), lwd=3)
Pacf(hata10, main="Hata PACF (Model 10)", lag.max=42, ylim=c(-1,1), lwd=3)
Box.test(hata10, lag=24, type="Ljung-Box")
checkresiduals(arima10)
library(forecast)

n <- length(hata10)
sinir_degeri <- 1.96 / sqrt(n)
acf_data <- Acf(hata10, lag.max=20, plot=FALSE)
acf_degerleri <- acf_data$acf[2:21]

# Sig. (P-Value) Hesaplama
# Formül:  $Z = ACF * \sqrt{n} \rightarrow P = 2 * (1 - pnorm(|Z|))$ 
z_skoru <- acf_degerleri * sqrt(n)
sig_degerleri <- 2 * (1 - pnorm(abs(z_skoru)))
tablo10 <- data.frame(
  Gecikme = 1:20,
  ACF = round(acf_degerleri, 3),
  Limit = round(sinir_degeri, 3),

```

```

Sig_Degeri = round(sig_degerleri, 3),
Durum = ifelse(sig_degerleri < 0.05,
               "ANLAMLI",
               "Anlamsız")
)
print(tablo10)

```

```

# Model: ARIMA(0,1,2)(0,2,2)[12]
arima11 <- Arima(veri_ts, order=c(0,1,2), seasonal=c(0,2,2), include.constant=TRUE)
coefest(arima11)
summary(arima11)
#anlamsız

```

```

# Model: ARIMA(0,1,2)(1,2,1)[12]
arima13 <- Arima(veri_ts, order=c(0,1,2), seasonal=c(1,2,1), include.constant=TRUE)
coefest(arima13)
summary(arima13)
#anlamsız

```

```

# Model: ARIMA(0,1,2)(1,2,0)[12]
arima12 <- Arima(veri_ts, order=c(0,1,2), seasonal=c(1,2,0), include.constant=TRUE)
coefest(arima12)
summary(arima12)
#anlamli
hata12 <- residuals(arima12)
Acf(hata12, main="Hata ACF (Model 12)", lag.max=42, ylim=c(-1,1), lwd=3)
Pacf(hata12, main="Hata PACF (Model 12)", lag.max=42, ylim=c(-1,1), lwd=3)
Box.test(hata12, lag=24, type="Ljung-Box", fitdf=3)
n <- length(hata12)
sinir_degeri <- 1.96 / sqrt(n)
acf_data <- Acf(hata12, lag.max=20, plot=FALSE)
acf_degerleri <- acf_data$acf[2:21] # İlk 20 gecikme

```

```

# Sig. (P-Value) Hesaplama
# Formül:  $Z = ACF * \sqrt{n} \rightarrow P = 2 * (1 - \text{pnorm}(|Z|))$ 
z_skoru <- acf_degerleri * sqrt(n)
sig_degerleri <- 2 * (1 - pnorm(abs(z_skoru)))

tablo12 <- data.frame(
  Gecikme = 1:20,
  ACF = round(acf_degerleri, 3),
  Limit = round(sinir_degeri, 3),
  Sig_Degeri = round(sig_degerleri, 3),
  Durum = ifelse(sig_degerleri < 0.05,
    "ANLAMLI",
    "Anlamsız")
)
print(tablo12)

# Model: ARIMA(0,1,2)(2,2,0)[12]
arima14 <- Arima(veri_ts, order=c(0,1,2), seasonal=c(2,2,0), include.constant=TRUE)
coefest(arima14)
summary(arima14)
#anlamlı

hata14 <- residuals(arima14)
Acf(hata14, main="Hata ACF (Model 14)", lag.max=42, ylim=c(-1,1), lwd=3)
Pacf(hata14, main="Hata PACF (Model 14)", lag.max=42, ylim=c(-1,1), lwd=3)
Box.test(hata14, lag=24, type="Ljung-Box", fitdf=4)

n <- length(hata14)
sinir_degeri <- 1.96 / sqrt(n)
acf_data <- Acf(hata14, lag.max=20, plot=FALSE)
acf_degerleri <- acf_data$acf[2:21] # İlk 20 gecikme

```

```

#Sig. (P-Value) Hesaplama
# Formül:  $Z = ACF * \sqrt{n} \rightarrow P = 2 * (1 - pnorm(|Z|))$ 
z_skoru <- acf_degerleri * sqrt(n)
sig_degerleri <- 2 * (1 - pnorm(abs(z_skoru)))
tablo14 <- data.frame(
  Gecikme = 1:20,
  ACF = round(acf_degerleri, 3),
  Limit = round(sinir_degeri, 3),
  Sig_Degeri = round(sig_degerleri, 3),
  Durum = ifelse(sig_degerleri < 0.05,
    "ANLAMLI",
    "Anlamsız")
)
print(tablo14)

# Model: ARIMA(1,1,2)(2,2,0)[12]
arima17 <- Arima(veri_ts, order=c(1,1,2), seasonal=c(2,2,0), include.constant=TRUE)
coeftest(arima17)
summary(arima17)
#anlamlı
hata17 <- residuals(arima17)
if(!is.null(dev.list())) dev.off()
Acf(hata17, main="Hata ACF (tahmin modeli)", lag.max=42, ylim=c(-1,1), lwd=3)
Pacf(hata17, main="Hata PACF (tahmin modeli)", lag.max=42, ylim=c(-1,1), lwd=3)
print(Box.test(hata17, lag=24, type="Ljung-Box", fitdf=5))
##ilk 20 gecikme
n <- length(hata17)
sinir_degeri <- 1.96 / sqrt(n)
acf_data <- Acf(hata17, lag.max=20, plot=FALSE)
acf_degerleri <- acf_data$acf[2:21]
z_skoru <- acf_degerleri * sqrt(n)
sig_degerleri <- 2 * (1 - pnorm(abs(z_skoru)))

```

```

tablo17 <- data.frame(
  Gecikme = 1:20,
  ACF = round(acf_degerleri, 3),
  Limit = round(sinir_degeri, 3),
  Sig_Degeri = round(sig_degerleri, 3),
  Durum = ifelse(sig_degerleri < 0.05,
    "ANLAMLI",
    "Anlamsız")
)
print(tablo17)

library(ggplot2)
model_uyum_degerleri <- fitted(arima17)
autoplot(veri_ts, series="Gerçek Veri") +
  autolayer(model_uyum_degerleri, series="Model Tahmini (Fitted)", lwd=1) +
  ggtitle("Model Uyumu: Gerçek Veriler ve Modelin Tahminleri") +
  xlab("Zaman") +
  ylab("Değerler") +
  theme_bw() +
  scale_color_manual(values=c("Gerçek Veri"="black", "Model Tahmini (Fitted)"="red")) +
  theme(legend.position="bottom")

# Model: ARIMA(0,1,2)(3,2,0)[12]
arima15 <- Arima(veri_ts, order=c(0,1,2), seasonal=c(3,2,0), include.constant=TRUE)
coefest(arima15)
summary(arima15)
#anlamlı
hata15 <- residuals(arima15)
Acf(hata15, main="Hata ACF (Model 15)", lag.max=42, ylim=c(-1,1), lwd=3)
Pacf(hata15, main="Hata PACF (Model 15)", lag.max=42, ylim=c(-1,1), lwd=3)
Box.test(hata15, lag=24, type="Ljung-Box", fitdf=5)

```

```

n <- length(hata15)
sinir_degeri <- 1.96 / sqrt(n)
acf_data <- Acf(hata15, lag.max=20, plot=FALSE)
acf_degerleri <- acf_data$acf[2:21] # İlk 20 gecikme

# Sig. (P-Value) Hesaplama
# Formül:  $Z = ACF * \sqrt{n} \rightarrow P = 2 * (1 - pnorm(|Z|))$ 
z_skoru <- acf_degerleri * sqrt(n)
sig_degerleri <- 2 * (1 - pnorm(abs(z_skoru)))

tablo15 <- data.frame(
  Gecikme = 1:20,
  ACF = round(acf_degerleri, 3),
  Limit = round(sinir_degeri, 3),
  Sig_Degeri = round(sig_degerleri, 3),
  Durum = ifelse(sig_degerleri < 0.05,
    "ANLAMLI",
    "Anlamsız")
)
print(tablo15)

# Model: ARIMA(0,1,2)(0,2,0)[12]
arima9 <- Arima(veri_ts, order=c(0,1,2), seasonal=c(0,2,0), include.constant=TRUE)
coefest(arima9)
summary(arima9)
#anlamlı
hata9 <- residuals(arima9)
Acf(hata9, main="Hata ACF (Model 9)", lag.max=42, ylim=c(-1,1), lwd=3)
Pacf(hata9, main="Hata PACF (Model 9)", lag.max=42, ylim=c(-1,1), lwd=3)
Box.test(hata9, lag=24, type="Ljung-Box", fitdf=2)

```

```

n <- length(hata9)
sinir_degeri <- 1.96 / sqrt(n)
acf_data <- Acf(hata9, lag.max=20, plot=FALSE)
acf_degerleri <- acf_data$acf[2:21]
# Sig. (P-Value) Hesaplama
# Formül:  $Z = ACF * \sqrt{n} \rightarrow P = 2 * (1 - pnorm(|Z|))$ 
z_skoru <- acf_degerleri * sqrt(n)
sig_degerleri <- 2 * (1 - pnorm(abs(z_skoru)))

tablo9 <- data.frame(
  Gecikme = 1:20,
  ACF = round(acf_degerleri, 3),
  Limit = round(sinir_degeri, 3),
  Sig_Degeri = round(sig_degerleri, 3),
  Durum = ifelse(sig_degerleri < 0.05,
    "ANLAMLI",
    "Anlamsız")
)
print(tablo9)

## Hem ACF hem PACF yavaş azalıyor. ARMA ##
library(forecast)
library(lmtest)
# Model: ARIMA(1,1,2)(1,2,1)[12]
arima16 <- Arima(veri_ts, order=c(1,1,2), seasonal=c(1,2,1), include.constant=TRUE)
coefest(arima16)
summary(arima16)
# anlamsız

#### arima17 modeli için öngörü ####
library(forecast)
# Gelecek 5 Ayın Tahmini

```

```

ongoru <- forecast(arima17, h=5)
tahmin_degerleri <- as.numeric(ongoru$mean)

# Öngörü Tablosu
tarihler_gelecek <- c("2018-01", "2018-02", "2018-03", "2018-04", "2018-05")

tablo_ongoru <- data.frame(
  Donem = tarihler_gelecek,
  Ongoru_Degeri = round(tahmin_degerleri, 2)
)

# Gerçek Verilerle Karşılaştırma Tablosu
son_gercekler <- tail(veri_ts, 10)

tarihler_gecmis <- c("2017-03", "2017-04", "2017-05", "2017-06", "2017-07",
  "2017-08", "2017-09", "2017-10", "2017-11", "2017-12")
tablo_gercek <- data.frame(
  Donem_Gercek = tarihler_gecmis,
  Gercek_Deger = round(as.numeric(son_gercekler), 2)
)

print(tablo_ongoru)
print(tablo_gercek)

autoplot(ongoru) +
  ggtitle("Tekstil Ürünleri İmalatı: 5 Aylık Gelecek Tahmini (2018)") +
  xlab("Yıl") +
  ylab("Endeks Değeri") +
  theme_bw()

```

8. Kaynakça

Kadılar, Cem ve Öncel Çekim, Hatice. (2025). *SPSS ve R Uygulamalı Zaman Serileri Analizine Giriş*. Seçkin Yayıncılık.

Ünal, Ceren. (2025). *İST489 Zaman Serileri Analizi Ders Notları*. Hacettepe Üniversitesi.